SPRINT 4

NIVELL 1

Descarrega els arxius CSV, estudia'ls i dissenya una base de dades amb un esquema d'estrella que contingui, almenys 4 taules de les quals puguis realitzar les següents consultes:

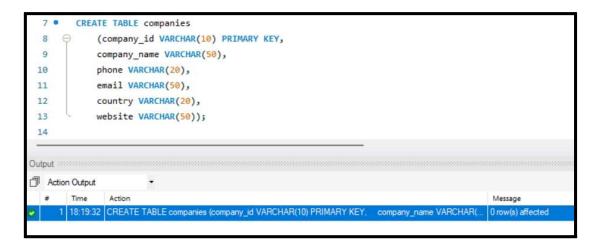
Primero creo una BBD nueva llamada Sprint_4:



Comienzo con la creación de la estructura de las tablas y definición del formato según el contenido del fichero csv: VARCHAR para cadenas, INT para números enteros, etc.

TABLA de dimensiones "companies":


- PRIMARY KEY: campo id que contiene identificadores únicos para cada uno de los registros
- Resto de campos: atributos de las empresas.



Compruebo que se haya creado la estructura correctamente mediante la cláusula SELECT:



Antes de importar, es necesario saber el directorio que MySQL tiene permitido usar para la importación de datos externos:



Verifico también el estado de la funcionalidad de carga de archivos locales:



Si el valor es "OFF" significa que está deshabilitada la función que permite la carga de archivos locales y, por tanto, hay que habilitarla mediante esta sentencia:



Comprobamos que ya aparece "ON" por lo que la función está habilitada:



Este comando carga los datos del archivo "companies.csv" desde el directorio "C:\Program Files\MySQL\MySQL Server 8.0\Uploads\companies.csv", que es el directorio permitido, y los inserta en la tabla companies. En la sentencia también indicamos las características del fichero:

- Los campos en el archivo CSV están separados por comas (línea de código 26)
- Están encerrados entre comillas dobles (27)
- Y además, la primera fila del archivo se ignora ya que contiene encabezados (28):

```
23 • LOAD DATA

24 INFILE 'C:\Program Files\MySQL\MySQL Server 8.0\Uploads\companies.csv'

25 INTO TABLE companies

26 FIELDS TERMINATED BY ','

27 ENCLOSED BY '"'


28 IGNORE 1 ROWS;
```

NOTA A LUCÍA: No he podido cargar los datos mediante código ya que me da un error de seguridad que no consigo corregir. Realizo la carga mediante la siguiente alternativa:

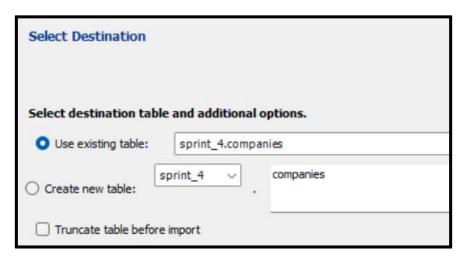
Visualizar la tabla y seleccionar la opción "Import record from an external file":




Seleccionar directorio:



Marcar la tabla ya existente "companies":




Comprobar que la correspondencia entre los campos de la tabla y las cabeceras del archivo sea correcta y que los valores de cada campo estén correctamente posicionados:




Para finalizar, comparar el mensaje con el fichero csv para comprobar que la importación se ha realizado con éxito (nota: en el fichero cvs salen 101 registros ya que incluye los encabezados):





Comprobar:




Repetir el proceso y crear todas las tablas de dimensiones: credit_cards, users_ca, users_uk y users_usa.

Hay 3 tablas con misma estructura que contienen los mismos datos de diferentes usuarios, la única diferencia entre ellas es el país de residencia. Como solo podremos relacionar una de ellas con la tabla de hechos, creo una nueva tabla unificando los datos de todos los usuarios y la almaceno con el nombre "total_users". Uso la cláusula "UNION" para descartar los duplicados:



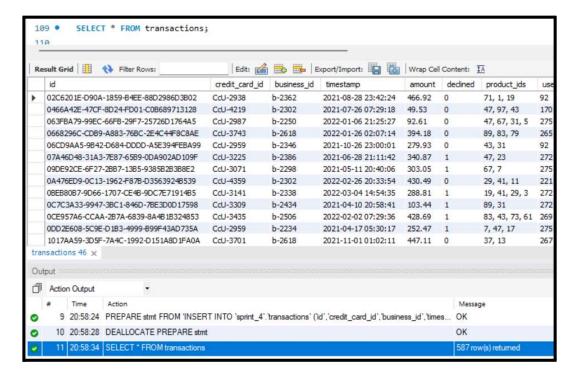
Modifico del campo "id" para definirlo como PRIMARY KEY, obligatorio para establecer relaciones con otras tablas:




Por último, creo la tabla de hechos "transactions" que tiene un identificador único "id" como PK, claves foráneas para relacionarla con las tablas de dimensiones: "credit_card_id", bussines_id y "user_id". El resto de campos son métricas atribuibles a cada "id" de cada transacción como la fecha, el importe, latitud y longitud y si la operación fue aceptada o declinada:

```
94
          CREATE TABLE transactions
 95
              (id VARCHAR(255) PRIMARY KEY,
              credit_card_id VARCHAR(15),
 96
              business id VARCHAR(20),
 97
              timestamp VARCHAR(50),
 98
 99
              amount DECIMAL(10,2),
100
              declined TINYINT(1),
101
              product_ids VARCHAR(50),
              user_id INT,
102
103
              lat FLOAT,
104
              longitude FLOAT,
105
              FOREIGN KEY (credit_card_id) REFERENCES credit_cards(id),
              FOREIGN KEY (user_id) REFERENCES total_users(id),
106
107
              FOREIGN KEY (business id) REFERENCES companies(company id));
Output
Action Output
         Time
                 Action
                                                                                                    Message
      1 20:55:04 CREATE TABLE total_users AS SELECT * FROM users_ca UNION SELECT * FROM users_uk UNION ... 275 row(s) affected
      2 20:55:51 ALTER TABLE total users ADD PRIMARY KEY (id)
                                                                                                   0 row(s) affected R
                CREATE TABLE transactions (i)d VARCHAR(255) PRIMARY KEY, credit_card_id VARCHAR(15), busi.
        20:57:06
                                                                                                   0 row(s) affected.
```

Importo los datos del fichero csv siguiendo el procedimiento explicado anteriormente y compruebo que se hayan insertado bien todos los registros:



En el diagrama de la nueva base de datos "Sprint_4", se observa un modelo estrella. Este modelo está compuesto por una tabla de hechos central denominada "transactions", la cual está rodeada por tres tablas de dimensiones con información sobre usuarios, compañías y tarjetas de crédito. Cada una de estas tablas de dimensiones se conecta directamente a la tabla de hechos a través de claves foráneas, estableciendo una relación de 1 a muchos:




Exercici 1

Realitza una subconsulta que mostri tots els usuaris amb més de 30 transaccions utilitzant almenys 2 taules:

Para realizar este ejercicio, primero he creado una subconsulta que cuenta todas las transacciones por usuario y filtrada por aquellos que tienen 30 o más transacciones mediante la cláusula HAVING.

Esta subconsulta también sirve para unir la tabla "total_users" con "transactions" utilizando la cláusula WHERE id IN, que combina los registros donde el campo "id" de la tabla "total_users" coincide con el campo "user_id" de "transactions" y que, además, tengan 30 o más transacciones registradas:

El resultado es que hay 4 usuarios que han realizado 30 o más transacciones:



Exercici 2


Mostra la mitjana d'amount per IBAN de les targetes de crèdit a la companyia Donec Ltd, utilitza almenys 2 taules:

Para realizar esta consulta, he utilizado tres tablas: "credit_cards" para obtener el IBAN, "transactions" para calcular el importe medio de las transacciones, y "companies" para filtrar por la compañía "Donec Ltd".

Primero, utilizo la instrucción SELECT para especificar los campos que deseo mostrar en la consulta. Aplico la función agregada AVG al campo amount para calcular el importe promedio de las transacciones por cada IBAN. Luego, con la cláusula GROUP BY, agrupo las filas según el número de IBAN, con lo que tenemos el importe promedio de las transacciones para cada grupo.

Combino las 3 tablas mediante "JOINS" y aplico filtro WHERE para indicar que devuelva sólo los IBAN de la compañía "Donec I td"

El resultado es que la empresa Donec Ltd, sólo ha usado 1 IBAN con un importe medio de transacciones de 203,72€



NIVELL 2

Crea una nova taula que reflecteixi l'estat de les targetes de crèdit basat en si les últimes tres transaccions van ser declinades i genera la següent consulta:

Exercici 1

Quantes targetes están actives?

Primero, es necesario modificar el formato del campo "timestamp" de la tabla "transacctions" y que actualmente está como VARCHAR y necesitamos pasarlo a DATE para poder hacer operaciones de fecha:




Para obtener la nueva tabla con los datos solicitados por el enunciado, primero necesitamos crear una CTE (Common Table Expression), que actúa como una vista temporal. Usamos la cláusula WITH para definir esta CTE, nombrándola "transactions_view". Luego, creamos la nueva tabla "new_transactions" a partir de los datos en la CTE.

Uso la función ROW_NUMBER() para asignar un número de registro correlativo a cada transacción, empezando en el número 1.

Con la cláusula PARTITION BY, agrupamos las transacciones por tarjeta de crédito, reiniciando el número de registro (ROW NUMBER) en cada salto de tarjeta.

Por ejemplo, aquí podemos ver claramente cómo funcionan ROW_NUMBER y PARTITION BY: la tarjeta de crédito 3891 tiene 17 registros, que han sido numerados del 1 al 17. Cuando se cambia a la tarjeta 3968, la numeración se reinicia y vuelve a empezar desde 1. Esto es lo que hace PARTITION BY: agrupa los registros por tarjeta y les asigna un número secuencial que se reinicia con cada nuevo grupo. Ver ejemplo, cada color es un nuevo grupo y el contador se reinicia de nuevo cada vez que cambia el color:



Ordeno cada partición de mayor a menor según la fecha de transacción utilizando la cláusula ORDER BY DESC.

Finalmente, para obtener las 3 últimas transacciones por cada tarjeta, filtro por aquellos registros (asignados con ROW_NUMBER) que sean menores o iguales a 3 que, al estar ordenadas por fecha descendente, coincidirán con las 3 últimas transacciones de cada tarjeta.


Por último, aplico un segundo filtro con AND para ver sólo las transacciones que no fueron rechazadas (declined False).

Aparecen 292 registros que cumplen las condiciones:

```
132 •
        CREATE TABLE new_transactions AS
133
        WITH transactions_view AS
134
            (SELECT *,
             ROW_NUMBER() OVER (PARTITION BY credit_card_id ORDER BY timestamp DESC) AS num_registro
135
             FROM transactions)
136
        SELECT *
137
138
        FROM transactions_view
139
        WHERE num_registro <= 3 AND declined = 0
140
        ORDER BY credit_card_id, num_registro;
Output .....
Action Output
   1 15:23:06 | CREATE TABLE new_transactions AS WITH transactions_view AS (SELECT*, ROW_NUMBER() OVE... | 292 row(s) affect
```

Para visualizar las tarjetas únicas activas de la nueva tabla, que es lo que pide el ejercicio, utilizo SELECT DISTINCT(credit_card_id).

Entendiendo que estás 275 tarjetas son las que siguen activas, que en realidad son todas las de la tabla "credit_cards":




NIVELL 3

Crea una taula amb la qual puguem unir les dades del nou arxiu products.csv amb la base de dades creada, tenint en compte que des de transaction tens product_ids. Genera la següent consulta:

La nueva tabla "products" es de dimensiones con el campo "id" como PRIMARY KEY:

```
CREACIÓN DE LA TABLA DE DIMENSIONES "PRODUCTS"
        CREATE TABLE products
151 •
152
            (id INT PRIMARY KEY,
153
            product_name VARCHAR(50),
154
            price VARCHAR(20),
155
            colour VARCHAR(20),
156
            weight DECIMAL(5, 2),
157
            warehouse_id VARCHAR(20));
Output
Action Output
       Time
```


Comprobamos e importamos los datos del fichero cvs según las instrucciones mencionadas en el Nivel 1.



Exercici 1

Necessitem conèixer el nombre de vegades que s'ha venut cada producte.


Antes de realizar esta consulta, es necesario crear una nueva tabla "by_product" y separar los datos del campo product_ids de la tabla "transactions". Actualmente, todos los productos vendidos en una única transacción están almacenados en una sola celda, separados por comas, lo que impide operar con ellos de manera adecuada. Debemos separarlos y convertir cada uno de ellos en un registro individual. También nos servirá para poder relacionar la nueva tabla con "products" y con "transactions" en una relación de muchos a uno como veremos más adelante en el nuevo diagrama:




Explicación detallada del código:

- > CREATE TABLE by_product AS : Creamos la nueva tabla y le damos el nombre "by_product"
- > SELECT: selecciono el campo id de la tabla "transactions" para poderla relacionar al modelo posteriormente.
- > SUBSTRING_INDEX(SUBSTRING_INDEX(product_ids, ',', numbers.n), ',', -1) AS product_id: Esta parte del código sirve para extraer los valores de la cadena del campo "product_ids" delimitados por comas.
 - o "numbers.n": Este código permite iterar sobre una secuencia de números, y extrae sucesivamente cada valor dentro de la cadena "product ids" separados por comas de la tabla "transaccions".
- ON CHAR_LENGTH(product_ids) CHAR_LENGTH(REPLACE(product_ids, ',', ")) >= numbers.n 1: Esto es una resta entre los dos fragmentos de código:
 - ON CHAR_LENGTH(product_ids) el primero (en azul) nos indica el número total de carácteres que hay en la cadena "product_ids" incluyendo las comas que los separa.
 - CHAR_LENGTH(REPLACE(product_ids, ',', ")) >= numbers.n 1: Esta parte, elimina las comas de la cadena y cuenta los carácteres que quedan. La resta entre los caracteres del fragmento azul menos la del verde, nos da el número de comas que hay en la cadena. Por ejemplo, en la siguiente cadena: '1,2,3', la longitud original es 5, y la longitud sin comas es 3: 123, por lo que la resta es 5 3 = 2. El número 2 indica cuántas comas hay en la cadena, lo que es equivalente al número de elementos en "product_ids" menos 1. Con este resultado el código sabe el número exacto de elementos hay que extraer de cada celda y convertirlos en registros separados.


Comprobación:



Ahora modifico el formato del campo "product_id" de la nueva tabla de VARCHAR a INT para poder crear una clave foránea y relacionarla con la tabla "products". Para que la relación sea correcta, ambos campos deben tener el mismo formato:




Por último creo una clave foránea en la tabla "by_product" en el campo id_Transaciones para relacionarla con "transactions":



Con estos cambios, ya tenemos relacionadas todas las tablas en nuestro modelo.

La tabla "transactions" está ahora relacionada con la nueva tabla derivada "by_product" mediante una relación de uno a muchos, donde cada registro en "transactions" puede estar asociado con múltiples registros en "by_product.".

Por otro lado, la tabla de dimensiones "products" se relaciona con la de hechos "by_product" estableciendo una relación de 1 a muchos.



Por último resuelvo el ejercicio donde tenemos que hallar cuantas veces se ha vendido cada producto mediante la función de agregación COUNT y uniendo mediante la cláusula JOIN la tabla "by product" con "products".

El resultado son 26 únicos productos vendidos en 1.457 transacciones:

